

LAPORAN IMPLEMENTASI DATA WAREHOUSE

ETL Data Sensor IoT Menggunakan Python dan SQLite

Dataset: processed_sensor_data_20250930_092513.csv

Teknologi: Python, Pandas, SQLAlchemy, SQLite

Arsitektur: Star schema

Status: Selesai dan tervalidasi

Tanggal laporan: 7 Oktober 2026

1. Ringkasan Eksekutif

Proyek ini mengimplementasikan pipeline Extract, Transform, Load (ETL) untuk memuat data pengukuran sensor IoT ke data warehouse berbasis SQLite. Data berhasil diekstrak, divalidasi, dibersihkan, ditransformasi, dimuat ke star schema, dan dianalisis menggunakan query SQL.

Hasil utama:

- 28.814 baris sumber diproses.
- 14.400 fact records unik tersedia di warehouse.
- Skor kualitas data: 100,0%.
- Empat tabel berhasil diverifikasi.
- Notebook berhasil dijalankan dari awal sampai akhir tanpa error.

2. Tujuan dan Sumber Data

Tujuan implementasi:

- Membangun pipeline ETL yang terstruktur dan dapat dijalankan ulang.
- Membersihkan dan memvalidasi data sensor sebelum dimuat.
- Merancang star schema untuk kebutuhan analitik.
- Menyediakan query untuk memperoleh insight kualitas udara.

Karakteristik dataset:

- Format: CSV; jumlah baris mentah: 28.814; jumlah kolom: 25.
- Terdapat 10 sensor, 5 lokasi, dan 1.440 kombinasi waktu.
- Kolom utama: timestamp, sensor, lokasi, suhu, kelembapan, tekanan, dan AQI.

3. Proses ETL

Extract: data dibaca menggunakan Pandas dari file CSV dan struktur kolom diperiksa sebelum transformasi.

Transform:

- Timestamp dikonversi ke tipe datetime.
- Nama lokasi distandardisasi.
- Baris duplikat dihapus dengan mempertahankan kemunculan pertama.
- Nilai numerik diperiksa terhadap batas kewajaran dan outlier ditangani.
- Nilai numerik kosong diisi menggunakan median kolom.

Load: data dimuat ke SQLite dengan batch processing, foreign key, dan index pada timestamp serta key dimensi.

Catatan deduplikasi: setelah standardisasi nama lokasi, 14.414 baris teridentifikasi sebagai duplikat dan dihapus. Hasil akhir adalah 14.400 record unik untuk fact table.

4. Rancangan Data Warehouse

Warehouse menggunakan star schema dengan satu fact table dan tiga dimension tables.

Tabel dan jumlah record:

- fact_sensor_readings: 14.400 - fakta pengukuran sensor.
- dim_sensors: 10 - master sensor.
- dim_locations: 5 - master lokasi.
- dim_time: 1.440 - tanggal, jam, periode, dan hari.

Index dibuat untuk mendukung query berdasarkan waktu, sensor, lokasi, dan dimensi waktu.

5. Validasi dan Hasil Analitik

Validasi:

- Kolom wajib tersedia.
- Timestamp berhasil dikonversi.
- Deduplikasi berhasil.
- Fact table berisi 14.400 record.
- Skor kualitas data: 100,0%.
- Notebook berjalan tanpa error setelah perbaikan sintaks.

Insight analitik:

- Lokasi dengan kualitas udara terbaik: Location_D.
- Lokasi dengan AQI tertinggi: Location_A.
- Periode dengan AQI rata-rata terendah: Night.
- Aktivitas sensor: seluruh sensor memiliki 1.440 pembacaan; tidak ada sensor tunggal yang paling aktif.
- Query tie-break memilih SENSOR_001 sebagai baris pertama, bukan karena jumlahnya lebih tinggi.

6. Kendala, Perbaikan, dan Kesimpulan

Kendala dan perbaikan:

- Ditemukan karakter asing pada data_loader.py yang menyebabkan IndentationError.

Karakter tersebut dihapus dan file lolos pemeriksaan sintaks.

- Ringkasan notebook diperbaiki agar membedakan record yang sudah ada di warehouse dari record yang dimuat pada run saat ini.

- Tampilan struktur proyek dibatasi agar tidak mencetak isi virtual environment.

Kesimpulan:

Implementasi data warehouse sensor IoT telah selesai dan memenuhi tujuan utama. Pipeline dapat membaca data, melakukan transformasi, memuat star schema, menjalankan analitik, dan menghasilkan metrik kualitas yang dapat diverifikasi.

Rekomendasi: gunakan scheduler seperti Airflow, dashboard monitoring, alert anomali, forecasting AQI, serta data governance.

Artefak: hands_on_data_warehouse.ipynb, src/data_loader.py, warehouse/sensor_warehouse.db, dan dataset CSV.

Link repository GitHub:

<https://github.com/Natan5906/Tugas-Data-WareHouse>